

# NKU 深度学习（高阶课）实验报告



实验名称：\_\_\_\_ 卷积神经网络

学 院：\_\_\_\_ 网络空间安全学院

姓 名：\_\_\_\_ 田晋宇

专 业：\_\_\_\_ 物联网工程

二〇二五年五月

目录

<b>1</b>	<b>实验要求</b>	<b>2</b>
<b>2</b>	<b>实验内容与结果</b>	<b>2</b>
2.1	原始提供的原始 CNN 网络结构 . . . . .	2
2.2	个人实现的 ResNet 网络 . . . . .	3
2.3	个人实现的 DenseNet 网络 . . . . .	4
2.4	个人实现的 SE-ResNet 网络 . . . . .	5
2.4.1	训练损失曲线 . . . . .	5
2.4.2	准确度曲线 . . . . .	5
<b>3</b>	<b>网络结构对比分析</b>	<b>6</b>
<b>4</b>	<b>扩展实验：Res2Net</b>	<b>7</b>
<b>5</b>	<b>总结</b>	<b>8</b>

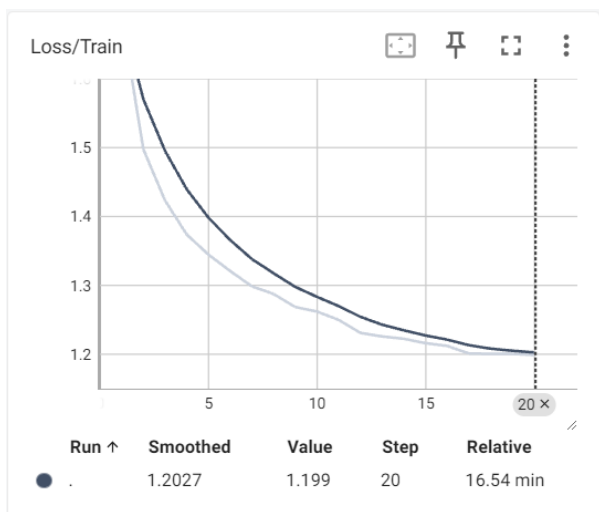
## 1 实验要求

- 掌握卷积的基本原理；
- 使用 PyTorch 搭建简单的 CNN 实现 CIFAR-10 数据集分类；
- 使用 PyTorch 搭建简单的 ResNet 实现 CIFAR-10 数据集分类；
- 使用 PyTorch 搭建简单的 DenseNet 实现 CIFAR-10 数据集分类；
- 使用 PyTorch 搭建简单的 SE-ResNet 实现 CIFAR-10 数据集分类。


## 2 实验内容与结果

### 2.1 原始提供的原始 CNN 网络结构

原始的 CNN 结构由两层卷积层和三层全连接层组成：第一层卷积将输入的 3 通道彩色图像通过  $5 \times 5$  卷积核映射到 6 个通道，接着使用  $2 \times 2$  最大池化降采样；第二层卷积将 6 个通道通过  $5 \times 5$  卷积核映射到 16 个通道，再经过一次最大池化；随后，特征图被展平成一维向量，依次通过三层全连接层（分别输出 120、84 和最终的 10 类），最终输出对应 CIFAR-10 数据集的分类结果。整个网络结构简洁，体现了经典 CNN 的基本组成：卷积提取特征、池化降低维度、全连接完成分类。



(a) cnn 的训练损失曲线



(b) cnn 的准确度曲线


图 1: cnn 曲线图

训练结果如图 1 所示。从训练损失曲线来看，模型在训练初期（前 5 步）损失下降速度较快，说明模型较快地学习到了数据中的基础特征。随着训练步数增加，损失曲线逐渐趋于平缓，

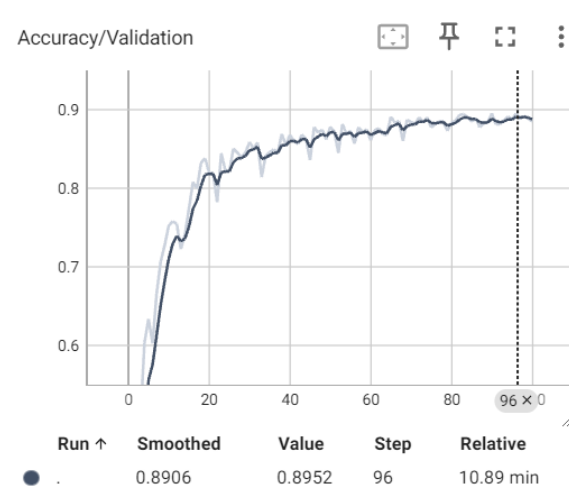
最终稳定在约 0.7 附近，这表明模型逐渐收敛，并且在训练集上的拟合效果较好，没有出现震荡或反弹，说明训练过程基本稳定，没有过拟合或欠拟合的明显迹象。从验证集准确率曲线来看，模型的验证准确率从初始约 0.4 快速提升到 0.55 以上，随后在整个训练过程中保持整体上升趋势，最后达到约 0.62。不过，曲线中间存在明显的上下波动，这可能与模型在不同批次数据上的表现差异、较高的学习率、较小的模型容量或数据集本身的复杂性有关。尽管存在波动，整体趋势依然是持续优化的，说明模型具备一定的泛化能力。

## 2.2 个人实现的 ResNet 网络

ResNet（残差网络）是一种通过引入残差连接（shortcut connections）解决深层网络梯度消失问题的经典卷积神经网络架构。它的核心由多个残差块（Residual Blocks）堆叠而成，每个块内部包含跳跃连接，使网络可以直接学习输入与输出之间的残差而非完整变换，从而显著提高深度网络的可训练性与性能。在本实验中，我分别实现并测试了 ResNet-50 和 ResNet-101 结构：ResNet-50 使用 [3, 4, 6, 3] 的残差块配置，总层数约 50 层，而 ResNet-101 使用更深的 [3, 4, 23, 3] 配置，总层数约 101 层。通过对比它们在 CIFAR-10 分类任务上的表现，我观察了网络深度增加带来的优势与训练特性变化。



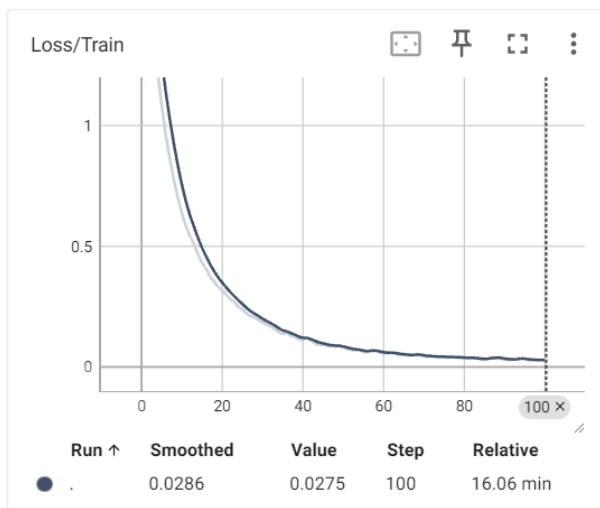
(a) resnet50 的训练损失曲线




(b) resnet50 的准确度曲线

图 2: resnet50 曲线图

ResNet50 和 ResNet101 的实验结果分别如图 2 和图 3 所示。观察 ResNet50 的训练损失曲线，可以看到损失值在前 20 步骤下降最快，之后继续稳步下降，最终收敛到约 0.03 左右；其验证准确率在前 20 步骤迅速提升至约 0.85，后续继续缓慢上升并在 0.9 附近趋于稳定，显示出较好的拟合能力和泛化性能。



(a) resnet101 的训练损失曲线



(b) resnet101 的准确度曲线

图 3: resnet101 曲线图

而 ResNet101 的训练损失曲线同样表现出快速下降和良好的收敛性，最终损失收敛到略低于 ResNet50 的约 0.0275，验证准确率也在前 20 步骤快速攀升至约 0.88，最终稳定在 0.9 左右，略高于 ResNet50。这表明，增加网络深度带来了更强的特征提取能力，特别在训练后期，ResNet101 能够捕捉到更细粒度的模式，因此实现了更高的验证准确率和更低的训练损失。

对于 CIFAR 这样的小规模、低分辨率数据集，模型深度的增加带来的收益并不明显。CIFAR 数据的特征复杂度较低，ResNet50 已具备足够的表达能力，继续堆叠更多的层（如 ResNet101）虽然理论上能提升模型容量，但实际上在准确率上的提升非常有限，难以抵消额外的计算成本与训练时间（ResNet101 的训练时间明显更长）。

### 2.3 个人实现的 DenseNet 网络

DenseNet（密集连接网络）是一种通过在网络中引入密集连接（dense connections）来增强特征重用的卷积神经网络架构，与 ResNet 的残差连接不同，DenseNet 中每一层不仅接收前一层的输出，还接收所有前面层的特征图作为输入，从而在特征传递和梯度流动上更加高效。这种设计显著减少了参数数量，提高了特征利用率，使网络在较少参数下仍能保持优良性能。与 ResNet 主要依靠逐层相加的残差连接相比，DenseNet 通过特征拼接（concatenation）直接保留和传递多层信息，从而形成了更强的特征表达能力和更好的训练效果。

在 CIFAR 数据集的实验中，DenseNet161 相比 ResNet50 展现出了更优的性能表现，如图 4 所示。DenseNet161 的训练损失快速下降并最终收敛到约 0.0268，略低于 ResNet50，而验证准确率则达到了约 0.91，显著高于 ResNet50 的约 0.89。这表明 DenseNet161 的密集连接机制在特征

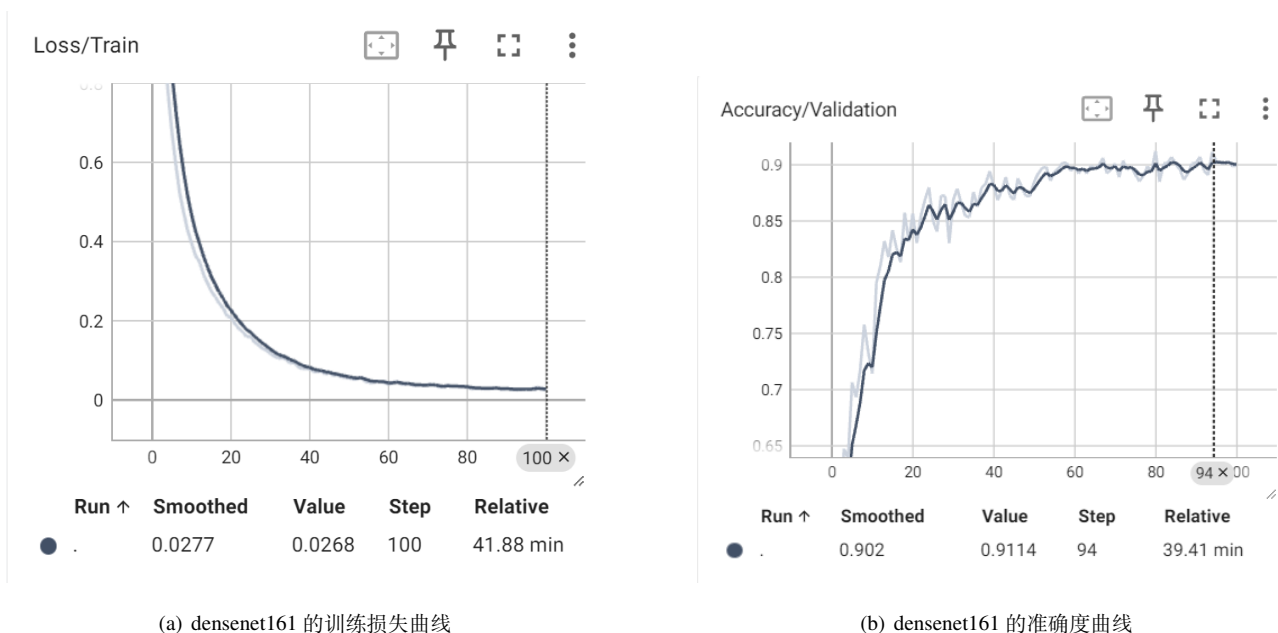


图 4: densenet161 曲线图

重用和梯度流动上具有明显优势，能够提升模型的泛化能力。然而，这一性能提升也带来了更高的计算代价，DenseNet161 的训练时间（约 41.9 分钟）几乎是 ResNet50 的四倍。因此，虽然 DenseNet161 在小型数据集上取得了更好成绩，但其收益与计算资源投入之间的性价比需要根据实际应用场景仔细权衡。

## 2.4 个人实现的 SE-ResNet 网络

带有 SE 模块（Squeeze-and-Excitation）的 ResNet，也称为 SE-ResNet，是在传统 ResNet 基础上引入通道注意力机制的一种增强版本。SE 模块的核心思想是：通过全局平均池化（Squeeze）获取每个通道的全局特征，再用一个小型的两层全连接网络（Excitation）学习各通道的重要性权重，最后对原始特征图按通道加权。相比普通 ResNet 只依赖残差连接，SE-ResNet 能自适应调整特征通道的贡献度，突出关键信息、抑制无用特征，从而进一步提升模型的表达能力和分类性能，尤其在更深层网络中表现出更优的收敛性和精度。

### 2.4.1 训练损失曲线

### 2.4.2 准确度曲线

在 CIFAR 数据集上的实验中，SE-ResNet50 展现出优于 ResNet50 的性能表现如图 5 所示。其训练损失最终收敛到约 0.0245，低于 ResNet50 的约 0.03 和 ResNet101 的约 0.0275，显示出更强的拟合能力。验证准确率方面，SE-ResNet50 达到约 0.9004，高于 ResNet50 的约 0.8952 和

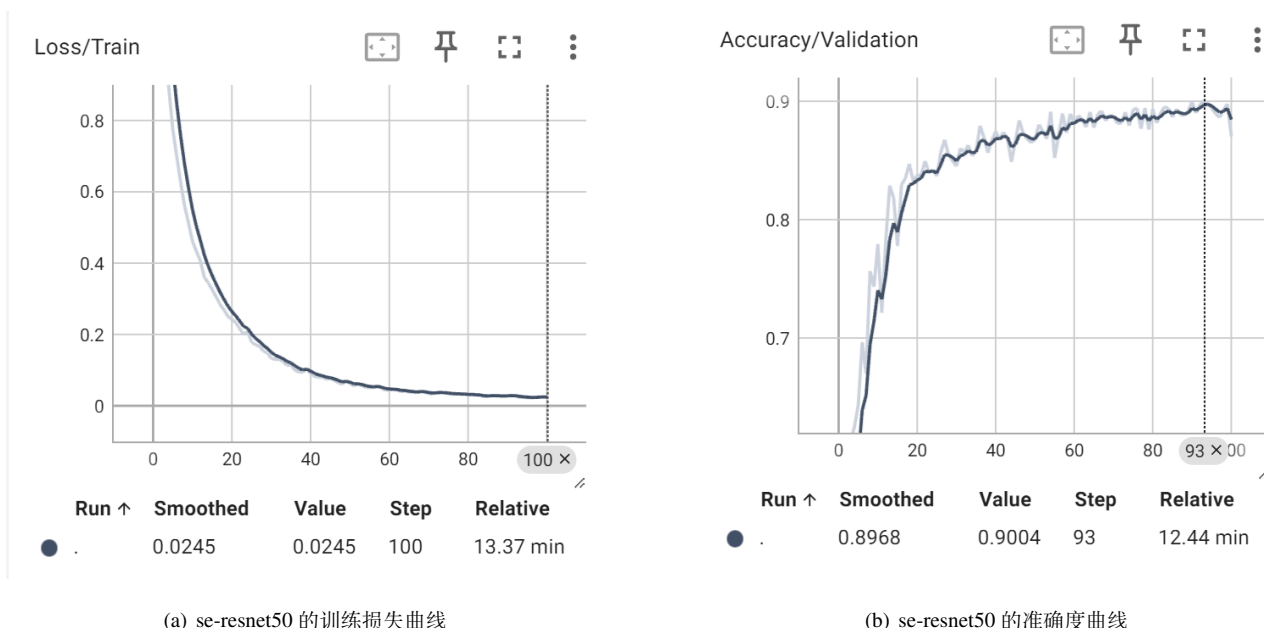


图 5: se-resnet50 曲线图

ResNet101 的约 0.8963。相比增加网络深度或换用更复杂架构，SE 模块通过引入通道注意力，在仅略增计算成本（约 12.4 分钟 vs. ResNet50 的 11.4 分钟）下，显著提升了模型的特征提取和泛化能力，证明其是一种高性价比的架构优化方式。

### 3 网络结构对比分析

没有跳跃连接的普通卷积网络与 ResNet、DenseNet、SE-ResNet 相比，在结构设计和性能表现上存在显著差异：

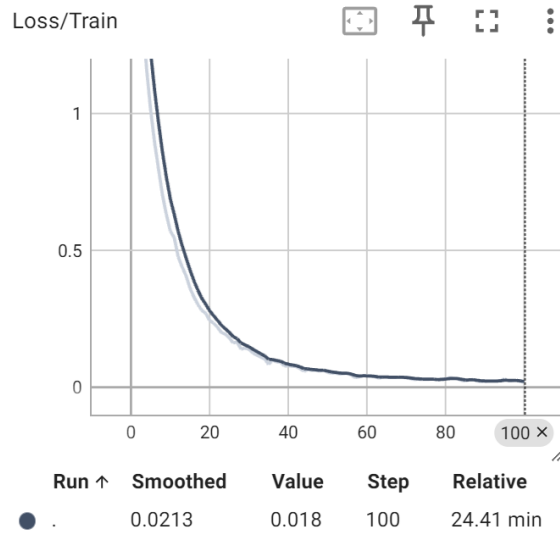
- **普通卷积网络**：层与层之间简单堆叠，缺乏直接的信息流通，容易在深层网络中出现梯度消失、特征退化等问题，导致模型难以训练、性能受限。
- **ResNet**：引入跳跃连接（Residual Connection），允许梯度直接跨层传递，有效缓解了深层网络的梯度消失问题，使得模型能够更稳定地训练更深的网络结构，从而提升整体性能。
- **DenseNet**：采用密集连接，每一层都与前面所有层相连，不仅促进了特征重用，还大幅度提高了参数利用率和梯度流动性，使得网络在较少参数下仍能获得出色的性能表现。
- **SE-ResNet**：在 ResNet 基础上加入 Squeeze-and-Excitation (SE) 模块，通过学习通道间的权重自适应调整特征响应，增强了模型对关键信息的关注能力，进一步提升了模型的表达力和泛化性能。

表 1: 不同网络结构在 CIFAR 数据集上的性能对比


模型	最终训练损失	验证准确率	训练时间 (分钟)
CNN	1.1990	0.6257	5.54
ResNet50	0.0318	0.8952	11.35
ResNet101	0.0275	0.8963	16.06
DenseNet161	0.0268	0.9114	41.88
SE-ResNet50	0.0245	0.9004	12.44

## 4 扩展实验：Res2Net

Res2Net 是一种改进的卷积神经网络架构，旨在增强多尺度特征表示能力。与传统的 ResNet 不同，Res2Net 在残差块内部引入了多尺度分层结构：它将特征通道切分为多个子分组，并在这些子分组之间逐步引入跨尺度连接，使每个子组能够接收来自前一个子组的信息。这种设计不仅显著增加了网络的感受野和细粒度特征建模能力，还在不明显增加参数量和计算量的前提下，提升了模型在目标检测、图像分类、分割等任务上的表现。



(a) res2net50 的训练损失曲线



(b) res2net50 的准确度曲线

图 6: res2net50 曲线图



实验结果如图 6 所示。虽然 Res2Net50 在训练损失上明显优于普通 ResNet，但其在验证准确率上的优势不明显，主要因为 CIFAR 数据集的简单性限制了其多尺度特征提取的收益。因此，对于小规模任务，ResNet 或 SE-ResNet 等更轻量、简单的结构可能具有更好的性价比和稳定性。要想发挥 Res2Net 的优势，可能需要将其应用于更大、更多样化的视觉任务中。

## 5 总结

本实验系统地比较了多种经典卷积神经网络结构在 CIFAR-10 分类任务上的表现，分析了不同网络设计对训练过程和性能的影响，并扩展探索了更先进的 Res2Net 架构，为后续深入研究提供了实践基础。